

EIGENVALUE DECOMPOSITION (Özdeğer Ayrıştırması)

14/15/19
2019

Denklemler Sistemi

$$y_1(t+1) = -y_1(t) - 1.5 y_2(t)$$

$$y_2(t+1) = 0.5 y_1(t) + y_2(t)$$

Katsayılar

$$A = \begin{bmatrix} -1 & -1.5 \\ 0.5 & 1 \end{bmatrix} \quad \bar{y}(t) = \begin{bmatrix} y_1(t) \\ y_2(t) \end{bmatrix}$$

$$\bar{y}(t+1) = A \cdot \bar{y}(t)$$

Çözüm önerisi

$$y_1(t) = x_1 \cdot \lambda^t \Rightarrow y_1(t+1) = x_1 \cdot \lambda^{t+1} \quad \lambda, x_1, x_2 \in \mathbb{R}$$

$$y_2(t) = x_2 \cdot \lambda^t \Rightarrow y_2(t+1) = x_2 \cdot \lambda^{t+1}$$

Denklemlerde yerine yazarsak

$$\begin{bmatrix} x_1 \cdot \lambda^{t+1} \\ x_2 \cdot \lambda^{t+1} \end{bmatrix} = \lambda^{t+1} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} -1 & -1.5 \\ 0.5 & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \lambda^t$$
$$\lambda \cdot \bar{x} = A \cdot \bar{x}$$

λ = Eigenvalue
(Özdeğer)

\bar{x} = Eigen Vector
(Özvektör)

A matrisini koraktı eder

Bir vektörü eigenvektörle görürsek sonuçta aynı yönde bir vektör olur

$\propto \lambda$ ve \bar{x} nasıl bulunur? $\lambda \in \mathbb{R}$ $A \in \mathbb{R}^{m \times n}$, $\bar{x} \in \mathbb{R}^m$

$$A \cdot \bar{x} = \lambda \cdot \bar{x}$$

$$A \cdot \bar{x} - \lambda \cdot \bar{x} = \bar{0}$$

$$\Rightarrow (A_{m \times n} - \lambda I_{m \times m}) \bar{x}_{m \times 1} = \bar{0}_{m \times 1}$$

- Öyle bir λ değeri bulalım ki

$A - \lambda \cdot I$ matrisi singular (tekill) matris olsun.

- Bunun için $\det(A - \lambda I) = \det(\lambda I - A) = 0$

Tersi alınmaz demektir.

$\rightarrow x$ 'e bağlı polinom

$$\chi_A(\lambda) = \det(\lambda I - A)$$

$$\chi_A(\lambda) = 0$$

Polinom denkleminin çözümü λ 'ları verir.

Örnek:

$$A = \begin{bmatrix} -1 & -1.5 \\ 0.5 & 1 \end{bmatrix}$$

$$X_A(\lambda) = \det(\lambda I - A) = \det\left(\begin{bmatrix} \lambda & 0 \\ 0 & \lambda \end{bmatrix} - \begin{bmatrix} -1 & -1.5 \\ 0.5 & 1 \end{bmatrix}\right)$$

$$\det \begin{bmatrix} \lambda+1 & 1.5 \\ -0.5 & \lambda-1 \end{bmatrix} = (\lambda+1)(\lambda-1) - 1.5(-0.5)$$

$$X_A(\lambda) = \lambda^2 - 1 + 0.75$$

$$X_A(\lambda) = \lambda^2 - 0.25 = 0$$

Karakteristik
polinom \Rightarrow

$$\lambda^2 = 0.25$$

$$\boxed{\lambda_1 = 0.5}$$

$$\boxed{\lambda_2 = -0.5}$$

Her bir eigenvalue karşılık bir eigenvektör vardır.

① $\lambda_1 = 0.5$ için

$$A \cdot \bar{x}_1 = \lambda_1 \cdot \bar{x}_1$$

$\bar{x}_1 \rightarrow \lambda_1$ e karşılık gelen
eigen vektör

$$\begin{bmatrix} -1 & -1.5 \\ 0.5 & 1 \end{bmatrix} \bar{x}_1 = 0.5 \cdot \bar{x}_1$$

$$\left(\begin{bmatrix} -1 & -1.5 \\ 0.5 & 1 \end{bmatrix} - 0.5 \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \right) \bar{x}_1 = \bar{0}$$

$$\begin{bmatrix} -1.5 & -1.5 \\ 0.5 & 0.5 \end{bmatrix} \bar{x}_1 = \bar{0}$$

$$\bar{x}_1 = \begin{bmatrix} x_{11} \\ x_{12} \end{bmatrix} \text{ olsun diyelim.}$$

$$\Rightarrow (-1.5)x_{11} - 1.5x_{12} = 0$$

$$(0.5)x_{11} + 0.5x_{12} = 0$$

$$x_{11} = -x_{12}$$

$$\boxed{x_{11} = \alpha} \mid \boxed{x_{12} = -\alpha} \text{ olsun diyoruz.}$$

$$\bar{x}_1 = \begin{bmatrix} \alpha \\ -\alpha \end{bmatrix} \quad \alpha \in \mathbb{R} \text{ eigenvektör ise}$$

$$\|\bar{x}_1\|^2 = 1 = \bar{x}_1^T \cdot \bar{x}_1$$

$$= [\alpha \ -\alpha] \begin{bmatrix} \alpha \\ -\alpha \end{bmatrix} = \alpha^2 + \alpha^2 = 2\alpha^2$$

$$2\alpha^2 = 1$$

$$\alpha^2 = \frac{1}{2} \quad \alpha = \frac{1}{\sqrt{2}}$$

$$\bar{x}_1 = \begin{bmatrix} \frac{1}{\sqrt{2}} \\ -\frac{1}{\sqrt{2}} \end{bmatrix}$$

$\lambda = 0.5$ için \bar{x}_1 'i bulduk.

② \subset

$$\lambda_2 = -0.5 \text{ için } \bar{x}_2 = \begin{bmatrix} x_{21} \\ x_{22} \end{bmatrix} \text{ yi bulalım}$$

$$A \cdot \bar{x}_2 = \lambda_2 \cdot \bar{x}_2$$

$$\left(\begin{bmatrix} -1 & -1.5 \\ 0.5 & 1 \end{bmatrix} + \begin{bmatrix} 0.5 & 0 \\ 0 & 0.5 \end{bmatrix} \right) \begin{bmatrix} x_{21} \\ x_{22} \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

$$\left. \begin{aligned} -0.5 x_{21} - (1.5) x_{22} &= 0 \\ 0.5 x_{21} + (1.5) x_{22} &= 0 \end{aligned} \right\}$$

$$x_{21} = -3 x_{22}$$

$$x_{22} = \alpha = \frac{1}{\sqrt{10}}$$

$$x_{21} = -3\alpha = \frac{-3}{\sqrt{10}}$$

$$\|\bar{x}_2\|^2 = 1 \Rightarrow \bar{x}_2^T \cdot \bar{x}_2$$

$$\begin{bmatrix} -3\alpha & \alpha \end{bmatrix} \begin{bmatrix} -3\alpha \\ \alpha \end{bmatrix} = 1$$

$$9\alpha^2 + \alpha^2 = 1$$

$$\alpha^2 = \frac{1}{10} \quad \alpha = \frac{1}{\sqrt{10}}$$

$$\lambda_2 = -0.5 \Rightarrow \bar{x}_2 = \begin{bmatrix} \frac{-3}{\sqrt{10}} \\ \frac{1}{\sqrt{10}} \end{bmatrix}$$

verilen denklem sisteminin çözümü

$$\bar{y}(t) = \begin{bmatrix} y_1(t) \\ y_2(t) \end{bmatrix} = (0.5)^t \begin{bmatrix} \frac{1}{\sqrt{2}} \\ -\frac{1}{\sqrt{2}} \end{bmatrix} \text{ ya}$$

$$= (-0.5)^t \begin{bmatrix} \frac{-3}{\sqrt{10}} \\ \frac{1}{\sqrt{10}} \end{bmatrix}$$

toplam çözüm

$$\bar{y}(t) = \lambda_1^t \cdot \bar{x}_1 + \lambda_2^t \cdot \bar{x}_2$$

$$\begin{bmatrix} y_1(t) \\ y_2(t) \end{bmatrix} = (0.5)^t \begin{bmatrix} \frac{1}{\sqrt{2}} \\ -\frac{1}{\sqrt{2}} \end{bmatrix} + (-0.5)^t \begin{bmatrix} \frac{-3}{\sqrt{10}} \\ \frac{1}{\sqrt{10}} \end{bmatrix}$$

Özellik $A \in \mathbb{R}^{m \times m}$ matrisi için tüm eigenvalue'lar birbirinden farklı ise, $\lambda_1 \neq \lambda_2 \neq \dots \neq \lambda_m$ bunlara karşılık gelen eigenvektörler $(\lambda_1 \rightarrow \bar{x}_1, \lambda_2 \rightarrow \bar{x}_2, \dots, \lambda_m \rightarrow \bar{x}_m)$ birbirinden bağımsızdır.

$$c_1 \cdot \bar{x}_1 + c_2 \cdot \bar{x}_2 + \dots + c_m \cdot \bar{x}_m = \bar{0}$$

$$\boxed{c_1 = c_2 = c_3 = \dots = c_m = 0}$$

Örnek: $\lambda_1 = 0.5$ $\lambda_2 = -0.5$

$$\bar{x}_1 = \begin{bmatrix} \frac{1}{\sqrt{2}} \\ -\frac{1}{\sqrt{2}} \end{bmatrix} \quad \bar{x}_2 = \begin{bmatrix} \frac{-3}{\sqrt{10}} \\ \frac{1}{\sqrt{10}} \end{bmatrix}$$

$$c_1 \begin{bmatrix} \frac{1}{\sqrt{2}} \\ -\frac{1}{\sqrt{2}} \end{bmatrix} + c_2 \begin{bmatrix} \frac{-3}{\sqrt{10}} \\ \frac{1}{\sqrt{10}} \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

$c_1 = c_2 = 0$ için sağlanır

Matrisin Köşegenleştirilmesi $A \in \mathbb{R}^{m \times m}$

Eigen Value denklem

$$A \cdot \bar{x}_i = \lambda_i \cdot \bar{x}_i \quad i=1,2,3,\dots,m$$

$$A \cdot x_1 = \lambda_1 \cdot \bar{x}_1$$

$$A \cdot x_2 = \lambda_2 \cdot \bar{x}_2$$

$$\vdots$$

$$A \cdot x_m = \lambda_m \cdot \bar{x}_m$$

$$\begin{bmatrix} A \cdot \bar{x}_1 & A \cdot \bar{x}_2 & A \cdot \bar{x}_m \\ | & | & | \\ | & | & | \end{bmatrix}_{m \times n} = \begin{bmatrix} \lambda_1 \cdot \bar{x}_1 & \lambda_2 \cdot \bar{x}_2 & \lambda_m \cdot \bar{x}_m \\ | & | & | \end{bmatrix}_m$$

$$\Rightarrow \underbrace{A}_{m \times n} \underbrace{\begin{bmatrix} \bar{x}_1 & \bar{x}_2 & \dots & \bar{x}_m \end{bmatrix}}_{m \times n} = \underbrace{\begin{bmatrix} \bar{x}_1 & \bar{x}_2 & \dots & \bar{x}_m \end{bmatrix}}_{m \times n} \underbrace{\begin{bmatrix} \lambda_1 & & 0 \\ 0 & \lambda_2 & \\ & & \ddots \\ 0 & & & \lambda_m \end{bmatrix}}_{m \times n}$$

$S \qquad \qquad \qquad S \qquad \qquad \qquad \Lambda$

$S = [\bar{x}_1 \ \bar{x}_2 \ \dots \ \bar{x}_m]$ eigenvalue 'lerin oluşturduğu matris

Köşegen matrisi $\Lambda = \begin{bmatrix} \lambda_1 & & 0 \\ & \lambda_2 & \\ 0 & & \ddots \\ & & & \lambda_m \end{bmatrix}$ eigenvalue 'lerin oluşturduğu köşegen matris

$$A \cdot S = S \cdot \Lambda$$

$$\Rightarrow \boxed{A = S \Lambda S^{-1}}$$

NÖT: Bir matrisin özdeğer ve özvektörlerini bilişsek matrisin kendisini oluşturabiliriz.

yalnız tüm λ değerleri birbirinden farklı ise

Örnek:

$$\lambda = 0.5 \quad \bar{x}_1 = \begin{bmatrix} \frac{1}{\sqrt{2}} \\ -\frac{1}{\sqrt{2}} \end{bmatrix}$$

$$\lambda_2 = -0.5 \quad \bar{x}_2 = \begin{bmatrix} -\frac{3}{\sqrt{10}} \\ \frac{1}{\sqrt{10}} \end{bmatrix}$$

eigenvalue ve
eigenvektörü
verilen A matrisini
olusturunuz

$$S = \begin{bmatrix} \frac{1}{\sqrt{2}} & -\frac{3}{\sqrt{10}} \\ -\frac{1}{\sqrt{2}} & \frac{1}{\sqrt{10}} \end{bmatrix} \quad \Lambda = \begin{bmatrix} 0.5 & 0 \\ 0 & -0.5 \end{bmatrix}$$

$$A = S \Lambda S^{-1}$$

$$A = S \Lambda S^{-1}$$

$$A \cdot S = S \cdot \Lambda$$

$$\boxed{S^{-1} \cdot A \cdot S = \Lambda}$$

→ Bir matrisin eigenvektörleri
biliniyorsa köşegen matrisi
 Λ bulunabilir

A^n 'in Hesaplanması

$$A = S \Lambda S^{-1}$$

$$A^2 = (S \Lambda S^{-1}) (S \Lambda S^{-1}) = S \Lambda^2 S^{-1}$$

$$\Lambda = \begin{bmatrix} \lambda_1 & 0 & 0 \\ 0 & \lambda_2 & 0 \\ 0 & 0 & \lambda_m \end{bmatrix} \quad \Lambda^n = \begin{bmatrix} \lambda_1^n & 0 & 0 \\ 0 & \lambda_2^n & 0 \\ 0 & 0 & \lambda_m^n \end{bmatrix} \Rightarrow \boxed{A^n = S \cdot \Lambda^n \cdot S^{-1}}$$

Matrisin fonksiyonu

$$f(t) = \sum_{i=1}^k f(i) t^i = f(1) \cdot t + f(2) t^2 + \dots + f(k) \cdot t^k$$

Verilen $A \in \mathbb{R}^{m \times m}$ için

$$f(A) = \sum_{i=1}^k f(i) \cdot A^i = \sum_{i=1}^k f(i) S \Lambda^i S^{-1} \\ = S \left(\sum_{i=1}^k f(i) \Lambda^i \right) S^{-1}$$

$$e^t = \sum_{i=0}^{\infty} \frac{t^i}{i!}$$

$$= 1 + t + \frac{t^2}{2!} + \frac{t^3}{3!} + \dots$$

$$e^A = S \left(\sum_{i=0}^{\infty} \frac{\Lambda^i}{i!} \right) S^{-1} \Rightarrow \boxed{e^A = S e^{\Lambda} S^{-1}}$$

EIGENDECOMPOSITION UYGULAMALARI

Karhunen - Loeve Expansion:

\bar{X} $m \times 1$ sıfır-ortalamalı (zero mean) random vektör olarak verilsin.

kovaryans matrisi $R = E\{\bar{X}\bar{X}^H\}$

R 'yi eigendecomposition yaptığımızı varsayarsak, $R = U \Lambda U^H$

$U = [\bar{U}_1 \bar{U}_2 \dots \bar{U}_m]$ \bar{U}_i : R 'nin normalize edilmiş eigenvektörleri

$\Lambda = \begin{bmatrix} \lambda_1 & & 0 \\ & \lambda_2 & \\ 0 & & \ddots \\ & & & \lambda_m \end{bmatrix}$ λ_i : R 'nin eigenvalue'sı.

$$U \cdot U^H = I$$

$\Rightarrow \bar{Y} = U^H \cdot \bar{X} \rightarrow \bar{Y}$ sıfır-ortalamalı random vektör

$$E\{\bar{Y}\bar{Y}^H\} = E\{U^H \bar{X} \bar{X}^H U\} = U^H E\{\bar{X} \bar{X}^H\} U$$

$$= U^H \cdot U \cdot \underbrace{\Lambda}_{R} \cdot \underbrace{U^H U}_I = \Lambda \text{ olur.}$$

$\Rightarrow \bar{X} = U \cdot \bar{Y}$ olur.

$$\Rightarrow \bar{X} = \sum_{i=1}^m \bar{U}_i y_i$$

\rightarrow random vektör \bar{X} 'i ortogonal vektörlerin (eigenvektörleri) lineer kombinasyonu olarak yazabiliriz.

Bu ağılıma "Karhunen-Loeve" ağırları denir.

Low-Rank Approximation:

Bazı durumlarda \bar{X} vektörünü $(*)$ 'de verilen] daha az sayıda eigenvektör kullanarak göstermek isteyebiliriz.

$$\tilde{X} \in \mathbb{C}^m$$

$$\tilde{X} = K \bar{X}$$

Burada K $m \times m$ boyutlu bir matris ancak rankı $r < m$ dir.

$$K = \sum_{i=1}^r \mu_i \bar{U}_i \bar{U}_i^H = U M_r U^H$$

$$M_r = \begin{bmatrix} \mu_1 & \mu_2 & \dots & \mu_r & 0 \\ & & & & \ddots \\ 0 & & & & 0 \end{bmatrix}$$

\tilde{x} ile \bar{x} arasındaki hatayı minimize etmek için

$$K = \sum_{i=1}^r \bar{u}_i \bar{u}_i^H = U I_r U^H$$

$$I_r = \begin{bmatrix} \overset{r \text{ tane}}{1} & & & 0 \\ & \ddots & & \\ & & 1 & \\ & 0 & & \ddots & 0 \\ & & & & 0 \end{bmatrix}_{m \times m}$$

PRINCIPAL COMPONENT METHOD

$\bar{x} \in \mathbb{R}^m$ zero-mean random vektör ise,

$\bar{x}_1, \bar{x}_2, \dots, \bar{x}_n$ n tane gözlem vektörü ise
(observation)

örneklem kovaryans matrisi
(sample covariance)

$$R = \frac{1}{n-1} \sum_{i=1}^n \bar{x}_i \bar{x}_i^T$$

R matrisinin eigenvektörleri $\bar{a}_1, \bar{a}_2, \dots, \bar{a}_m$ olsun. Bunlara karşılık gelen eigenvalue'lar $\lambda_1, \lambda_2, \dots, \lambda_m$.
 $\langle \bar{a}_i, \bar{a}_j \rangle = 0$ eigenvektörler birbirine ortogonal. $\|\bar{a}_i\| = 1$

~~data~~ $X = [\bar{x}_1 \ \bar{x}_2 \ \dots \ \bar{x}_n]$ data matrisi.

$$y_{1,i} = \bar{a}_1^T \bar{x}_i$$

→ 1st principal component (eigenvektör ile data vektörün iç çarpımı)

$$\begin{aligned} \text{sample-variance: } \sigma_{y_1}^2 &= \frac{1}{n-1} \sum_{i=1}^n y_{1,i}^2 = \frac{1}{n-1} \sum_{i=1}^n (\bar{a}_1^T \bar{x}_i)^2 \\ &= \frac{1}{n-1} \sum_{i=1}^n \bar{a}_1^T \bar{x}_i \bar{x}_i^T \bar{a}_1 = \bar{a}_1^T \left(\frac{1}{n-1} \sum_{i=1}^n \bar{x}_i \bar{x}_i^T \right) \bar{a}_1 \\ &= \bar{a}_1^T R \bar{a}_1 \end{aligned}$$

$$\Rightarrow \sigma_{y_1}^2 = \bar{a}_1^T R \bar{a}_1 = \bar{a}_1^T \lambda_1 \bar{a}_1 = \lambda_1 \underbrace{\bar{a}_1^T \bar{a}_1}_{=1} = \lambda_1$$

eigenvalue denklemini $\Rightarrow R \bar{a}_1 = \lambda_1 \bar{a}_1$


Benzer şekilde k . principal component

$$y_{k,i} = \bar{a}_k^T \bar{x}_i$$

→ $y_{k,i}$ 'nin sample-variansı = λ_k olur.

Bu şekilde bir sinyalin varyansının çoğunluğu r tane principal component tarafından içerilirse, sinyalin kendisi yerine bu principal componentlar kullanılabilir.

Örnek :



$\bar{X}_1, \bar{X}_2, \dots, \bar{X}_{200} \rightarrow 200$ tane data vektörü $\bar{X}_i = \begin{bmatrix} x_{i1} \\ x_{i2} \end{bmatrix}$

Sample-kovaryans matrisi

$$R = \frac{1}{200-1} \sum_{i=1}^{200} \bar{X}_i \bar{X}_i^T = \begin{bmatrix} 24.1893 & 10.6075 \\ 10.6075 & 6.38059 \end{bmatrix}$$

R'nin eigenvalue'ları $\lambda_1 = 29.1343$ $\lambda_2 = 1.4355$

" eigenvektörleri $\bar{a}_1 = [0.9064 \ 0.4225]^T$ $\bar{a}_2 = [-0.4225 \ 0.9064]^T$

\Rightarrow random vektör $\bar{X}_i = [x_{i1} \ x_{i2}]^T$ için

1. principal component = $y_1 = \bar{a}_1^T \bar{X}_i = 0.9064 x_{i1} + 0.4225 x_{i2}$

$y_1 \rightarrow$ skaler (1. principal component)

y_1 değeri \bar{X}_i vektörünün varyansının 95%'ini barındırır.

Birçok istatistiksel amaç için \bar{X}_i vektörünün iyi bir yaklaşımıdır.